

Scoring bancaire, analyse statistique et Machine Learning

FINALITÉ DU PROJET Développer un outil automatisé d'aide à l'octroi de crédit capable d'identifier les profils risqués, de produire une grille de score compréhensible et de mesurer le gain apporté par des modèles de Machine Learning plus complexes.

1. PROBLÉMATIQUE ET OBJECTIFS

PROBLÉMATIQUE Comment fiabiliser et accélérer la décision d'octroi de crédit tout en limitant les défauts de paiement, les refus de clients solvables et le risque de décisions opaques ?	3 OBJECTIFS IMPOSÉS • Décrire le portefeuille clients et repérer les facteurs de risque. • Construire une grille de score issue d'une régression logistique. • Challenger cette grille avec plusieurs modèles de Machine Learning.
---	---

2. DONNÉES UTILISÉES

VOLUME 307 511 clients 22 variables Données numériques et catégorielles	CIBLE GOOD_PAYER 1 : aucun retard 0 : retard de remboursement	CONTENU Informations personnelles et financières : genre, situation familiale, logement, revenus, montant et objet du crédit, âge, ancienneté d'emploi, profession, secteur d'activité et scores externes de bureaux de crédit.
---	---	---

3. MÉTHODOLOGIE MISE EN ŒUVRE

01 - NETTOYAGE Analyse de 7 variables incomplètes (0,09 % à 56,38 % de valeurs manquantes). Suppression de EXT_SOURCE_1 et TOTALAREA_MODE au-delà de 40 % ; imputations conditionnelles, catégorielles et KNN pour le reste. Traitement de la valeur extrême de revenu à 117 M et transformations logarithmiques.	02 - EXPLORATION Statistiques descriptives, normalité, skewness, kurtosis, ANOVA, corrélations de Pearson, taux de risque, WOE, IV, Gini et tests de significativité. Les scores EXT_SOURCE_2 et EXT_SOURCE_3 ressortent comme les variables numériques les plus discriminantes.
03 - PRÉPARATION Découpage stratifié train / validation / test en 60 % / 20 % / 20 %. La cible étant déséquilibrée (91 % de bons payeurs, 9 % de mauvais), pondération inverse des classes plutôt qu'oversampling afin de conserver toutes les observations.	04 - TRANSFORMATION One-Hot Encoding et indicatrices imbriquées pour les catégories, regroupements par fréquence ou taux de risque, scaling et binning des variables numériques. Suppression des prédicteurs à IV < 0,02.

Projet réalisé en équipe avec Alexandra Millot et Ismail Ouazzani Chahdi

4. SOLUTIONS CONSTRUITES

GRILLE DE SCORE - RÉGRESSION LOGISTIQUE

- Sélection ascendante selon l'AIC, la vraisemblance et la significativité des coefficients.
- Réduction progressive de 23 à 20 puis 14 variables grâce aux p-values, à l'IV, au VIF et au Lasso.
- Grille finale limitée à 6 variables, normalisée avec une référence de 500 points, un facteur 2 et 20 points par doublement des odds.
- Correction des incohérences de monotonie par lissage et regroupement adaptatif.
- Évaluation par Gini, KS, déciles, courbe de concentration et courbe d'équilibre financier.

CHALLENGE MACHINE LEARNING

- Modèles testés : Naive Bayes, arbre de décision, KNN, Random Forest, Gradient Boosting, XGBoost et réseau de neurones.
- Optimisation par validation croisée, GridSearchCV pour Random Forest et Optuna pour XGBoost.
- Comparaison selon l'AUC-ROC, le Gini et le F1-score.
- Interprétation via importance interne des arbres, valeurs SHAP et permutation importance.
- Réentraînement des meilleurs modèles sur les quatre variables les plus influentes.

5. RÉSULTATS OBTENUS

XGBOOST

AUC = 0,7088
Gini = 0,4175
Meilleure performance globale

VARIABLES DOMINANTES

EXT_SOURCE_2 et EXT_SOURCE_3,
suivies de YEARS_EMPLOYED et
AGE_YEARS.

GRADIENT BOOSTING

AUC = 0,7083
Gini = 0,4167
Performance quasi équivalente

MODÈLES SIMPLIFIÉS

AUC presque inchangée après
réentraînement sur 4 variables : 0,7083
pour Gradient Boosting et 0,7086 pour
XGBoost.

RANDOM FOREST

AUC = 0,7066
Gini = 0,4132
Résultat robuste et proche

IMPACT ÉCONOMIQUE

Avec le seuil et les coûts retenus, les
modèles conduisent à une perte
similaire d'environ -3 684,72 : la
performance statistique seule ne suffit
donc pas.

6. CONCLUSION ET VALEUR DU PROJET

Le projet aboutit à une chaîne de scoring complète, depuis la donnée brute jusqu'à la décision métier. Il montre que XGBoost et Gradient Boosting améliorent la discrimination, mais que leur intérêt opérationnel dépend du calibrage du seuil et des coûts d'erreur. La réduction à quatre variables conserve presque toute la performance et renforce la simplicité, la stabilité et l'explicabilité du dispositif.

Compétences démontrées : data cleaning, analyse statistique, sélection de variables, scoring, optimisation de modèles, interprétabilité, évaluation économique et restitution claire à un décideur.

7. LIMITES ET PERSPECTIVES

CALIBRAGE MÉTIER

Revoir le coût des faux positifs et faux négatifs ainsi que le seuil de décision pour traduire correctement la rentabilité bancaire.

ENRICHISSEMENT

Ajouter des historiques comportementaux, des variables transactionnelles et un feature engineering plus poussé.

INDUSTRIALISATION

Mettre en place suivi de dérive, recalibrage périodique, API de scoring et tableau de bord de contrôle.

Python - pandas - NumPy - SciPy - statsmodels - scikit-learn - XGBoost - Optuna - SHAP - matplotlib / seaborn / plotly